

회전체 RUL 예측 챌린지

데이터 전처리 및 딥러닝 기반 잔존 수명 예측 프레임워크

이경민 · 박성현 · 배준석 · 정주현 | 아주대학교 기계공학과

분석 목표 및 챌린지 핵심 과제

01

고정밀 잔존 수명(RUL) 예측

- 초(Second) 단위의 정밀 예측 수행
- Late Prediction Penalty: 실제 수명 초과 예측 시 강력한 패널티 부과
- 열화 초기 시점(FPT) 탐지가 성패의 핵심

02

비정상 신호 특징 추적

- 미세 결함 주파수 성분의 시간적 변화 모니터링
- 점진적 마모 및 간헐적 충격 에너지 분석

진동 데이터 수집



신호 전처리 / 특징 추출



모델 학습



RUL 예측

데이터 파이프라인 개요

핵심 챌린지 초(second) 단위 예측 정밀도 + 비대칭 패널티 구조(늦은 예측 > 이른 예측) + 가변 회전 속도 환경 대응

베어링 물리 특성 및 결함 주파수 이론



30306 테이퍼 롤러 베어링

n: 롤러 수

d: 전동체 지름

D: 피치 지름

Φ: 접촉각

$$BPFO = \frac{n \cdot f_r}{2} \left(1 - \frac{d}{D} \cos \phi \right)$$


$$BPFI = \frac{n \cdot f_r}{2} \left(1 + \frac{d}{D} \cos \phi \right)$$

결함 주파수	값 (Hz)
BPFI (내륜)	140 Hz
BPFO (외륜)	93 Hz
BSF (볼)	78 Hz
Cage	6.7 Hz

AI 모델 관점: 결함 주파수의 의미

- ▶ BPFI/BPFO/BSF는 결함 유형별로 스펙트럼에 규칙적인 피크(Peak)를 생성 → FFT/STFT 후 해당 주파수 bin이 핵심 Feature
- ▶ RPM에 따라 결함 주파수가 선형 비례 → 가변 속도 환경에서는 Order 분석(정규화 주파수)으로 변환 필요
- ▶ 고조파(2x, 3x...) 포함 시 CNN의 패턴 학습 이점 → NFFT 해상도 설정 시 고조파 포함 여부 고려
- ▶ Cage 주파수(6.7Hz)는 저주파 노이즈에 매몰되기 쉬움 → Bandpass 필터 또는 해당 대역 마스킹 권장

베어링 물리 특성 및 결함 주파수 이론




공진 증폭 현상

회전체 결함 → BPFO/BPFI 대역 주파수 발생
→ 금속 구조물 공진으로 에너지 증폭 →
SNR 높은 충격파 생성 (약 1000Hz 대역)

ML 학습 시 주목할 대역

- 에너지가 크고 SNR 높은 1kHz 근방 충격파
→ 특징 추출 1순위
- 저주파 노이즈에 묻히지 않는 대역 집중
필터링
- 스펙트로그램 입력 시 해당 주파수 구간
강조

RAW 데이터 특성



진동 (TDMS)

25.6kHz · 4채널 가속도계
60초 수집 / 540초 휴지 반복
고장 시점 수집 누락 가능

온도 / 토크 (CSV, 0.1Hz)

고장 판단 지표 · 운전 조건 정규화용

ML 관점에서의 핵심 과제

클래스 불균형

정상 구간(~90%) vs. 고장 직전 →
Weighted Loss / Focal Loss / GAN
Oversampling

RUL 레이블링

고장 시점 역산(countdown): $RUL_i = T_f - t_i$ · Linear vs. Piece-wise Linear
선택

시계열 불연속


60s ON / 540s OFF → segment를 독립
샘플로 취급, 슬라이딩 윈도우 경계
주의

RPM 정규화

속도 의존적 신호 진폭 → 운전 조건
기반 정규화(Order 분석) 필수 선행

RAW 데이터 특성

Integrated Bearing Health Monitoring
[Failure Diagnosis: Torque Limit Reached (Rear Suspected)]



예시: Train1

후방 베어링 파손 진단 (토크 감소 임계 초과)
Cage 결함주파수 및 기타 주파수의 피크 감지
축방향 센서의 민감한 감지

ML 문제 정의: 베어링 진동 데이터 → RUL 회귀 파이프라인

INPUT

진동 신호 (.TDMS)

25.6kHz · 4채널 가속도계
60s 수집 / 540s 휴지 (불연속)
1 segment = 1.536M points

온도 / 토크 (.CSV, 0.1Hz)

RPM 정규화용 보조 특징
고장 판단 임계값 기준

⚠ 클래스 불균형

정상(~90%) >> 고장 직전
→ Focal Loss / GAN 보정

PROCESSING

① 전처리 (Denoising)

VMD · STFT · DWT

② 특징 추출

STFT Spectrogram (2D CNN 입력)
Time-Domain Stats: RMS, Kurtosis, Crest

③ RUL 레이블 생성

$RUL_i = T_i - t_i$ (초 단위 역산)
Piece-wise Linear 단조 함수 권장

④ 데이터 증강

GAN · Noise Injection · Time Warping

OUTPUT

RUL 예측값 (초 단위)

순수 회귀(Regression) 문제
초(second) 단위 정밀 예측 필요

비대칭 평가 구조

늦은 예측(+오차): 강한 패널티
이른 예측(-오차): 상대적으로 완화

핵심 도전 과제

- ▶ FPT(열화 초기) 조기 탐지
- ▶ 도메인 불변 표현 학습
- ▶ 높은 정확도 점수 달성

$$A_{\{RUL\}} = \begin{cases} \exp(-\ln(0.5) \cdot Er_{i/20}) & \text{if } Er_i \leq 0 \\ \exp(+\ln(0.5) \cdot Er_{i/50}) & \text{if } Er_i > 0 \end{cases}$$

데이터 전처리 및 잡음 제거 (Denoising)

▼ VMD 분해

비정상 신호를 유의미한 하위 성분(IMF)으로 분해하여 배경 노이즈와 진단 신호를 분리

ML 효과 → Feature 차원 감소 및 과적합 방지

▼ 스펙트럴 차감

초기 상태의 노이즈 프로파일을 추정하여 STFT 결과에서 감산, SNR 극대화

ML 효과 → SNR 향상으로 Loss 수렴 안정화

▼ WMA 평활화


Weighted Moving Average를 적용하여 신호의 급격한 변동을 억제하고 추세 강조

ML 효과 → HI 단조성(Monotonicity) 향상으로 RUL 회귀 정확도 개선

⚠ 핵심 선행 조건: 가변 회전속도 환경에서 신호 진폭이 RPM에 비례 → 운전 조건(RPM) 기반 정규화(Normalization) 반드시 수행

시간-주파수 도메인 특징 추출 (1/4) — STFT & Spectrogram

Denoised Spectrogram Grid (Spectral Subtraction Applied)



STFT & Spectrogram


시간에 따른 주파수 에너지 분포를 2D 이미지로 변환하여 CNN 모델의 직접 입력으로 활용

Spectral Centroid 분석을 통해 배경노이즈 감산 및 열화 진행에 따른 중심 주파수의 저주파 이동(Shift) 현상 감지 가능

구현 권장 파라미터


- NFFT: 512~1024 (결함 주파수 고조파 포함)
- 주파수 범위: 0~5kHz (SNR 고려)
- 정규화: Log-Mel 또는 dB 스케일

시간-주파수 도메인 특징 추출 (2/4) — Continuous Wavelet Transform




CWT

고주파 대역: 높은 시간 해상도
저주파 대역: 높은 주파수 해상도
→ 충격 성분 포착에 최적화된 다중해상도 분석



시간-주파수 도메인 특징 추출 (3/4) — Discrete Wavelet Transform




DWT

컴퓨터를 통한 분석이 용이하도록 이산화 및 최적화
연산량 감소, 실시간 노이즈 제거 성능이 강점

STFT vs Wavelet 선택 기준

- STFT → 일정한 시간-주파수 해상도, CNN 2D 입력에 적합
- CWT → 충격 성분 정밀 포착, 연산 비용 높음
- DWT → 낮은 연산 비용, 실시간 처리 적합
- 권장: STFT(Spectrogram)를 기본 입력으로, CWT를 보조 feature로 활용

시간-주파수 도메인 특징 추출 (4/4) — VMD



VMD((Variational Mode Decomposition)

시계열 신호를 유의미한 하위 성분으로 분해하여,
배경 노이즈를 배제한 진단 대상 신호만을 분리

초기 미세결함에 의한 고장주파수 및 고조파의 돌출

이후 결함 확산에 의한 Baseline RMS 증가

건강 지수(HI) 생성 및 특징 선정

Feature Importance 및 단조성 분석

Feature	Monotonicity	Trendability	Robustness	Total Score
Crest Factor	0.056	0.325	0.628	0.336
RMS	0.040	0.165	0.402	0.202
Kurtosis	0.008	0.148	0.426	0.194

SoftMax Pooling 가중치 통합

상관 분석(Correlation Index)을 통해 기여도가 높은 채널에 가중치를 부여,
다중 특징을 단일 Health Indicator(HI)로 통합
→ 단조 감소하는 HI를 모델의 회귀 타겟 또는 보조 입력으로 활용

HI가 ML에 중요한 이유

- ① 단조성(Monotonicity)
열화 방향성 확보 → 회귀 모델이 RUL 감소 방향
쉽게 학습
- ② 추세성(Trendability)
노이즈 대비 신호 명확성 → Loss 수렴 안정화
- ③ 강건성(Robustness)
운전 조건 변화에 둔감 → 도메인 일반화 향상

권장: HI를 보조 입력 또는 Multitask Loss 구성요
소로 활용

데이터 증강을 통한 모델 일반화

× Noise Injection

다양한 SNR 수준의 백색 가우시안 노이즈를 추가하여 환경 변화에 대한 강건성 확보

SNR 5~20dB 범위에서 랜덤 적용. 실제 산업 환경의 전기적 노이즈 시뮬레이션

↔ Time Warping

신호 속도를 미세하게 조절하여 가변 회전 속도 환경에서의 데이터 부족 문제 해결

최대 $\pm 10\%$ 속도 변화 적용. 회전 주파수 편이에 강건한 모델 학습

🔄 GAN 기반 생성

Generative Adversarial Network로 부족한 '고장 근접' 상태의 합성 데이터를 생성

Sobol Sampling: 물리 기반 샘플링으로 Run-to-failure 시퀀스 확장 가능

증강 전략 권장 고장 근접 구간($RUL < 20\%$)에 집중 증강 → 클래스 불균형 보정. GAN 합성 데이터는 검증 세트에서 제외하여 Leakage 방지

학습 모델 선정 (1/2) — Hybrid CNN-LSTM with Attention

CNN Part


주파수 스펙트로그램에서 공간적 특징 및 결함 패턴 추출.
Conv1D 블록으로 시계열 국소 패턴 포착

LSTM Part

시간에 따른 열화 진행 과정 학습. 장기 의존성(Long-term dependency) 파악에 특화

Attention Mechanism

급격한 에너지 변화 시점에 가중치 부여 → 열화 초기(FPT) 감지
정확도 향상



학습 모델 선정 (2/2) — PSR-Transformer & 모델 비교

모델 아키텍처 성능 비교

Transformer의 강점

병렬 처리 가능 + Self-Attention으로 LSTM보다 훨씬 긴 시퀀스의 맥락 파악에 유리. 전체 열화 이력을 한번에 학습 가능.

PSR: Positional Signal Representation — 연속 진동 시계열에 특화된 위치 인코딩 기법으로 열화 단계 순서 보존

[권장] 최종 구현 가이드

- ▶ Encoder: Multi-head Attention (heads=8, d=128) + 가변 길이 Mask 적용
- ▶ Domain Adaptation: ADTL / DANN 레이어로 RPM·부하 조건 간 도메인 이동 극복
- ▶ 단계적 접근: SVR → CNN-LSTM → Transformer 순으로 성능 검증
- ▶ 과적합 주의: 데이터 소량 시 Dropout(0.2) + Label Smoothing + 증강 병행

성능 평가 지표 및 최종 검증

① RMSE (Root Mean Square Error)

예측값과 실제 수명의 물리적 거리 측정. 오차의 크기를 직접적으로 반영하는 기본 지표.

$$RMSE = \sqrt{\left(1/N \cdot \Sigma (RUL_{pred} - RUL_{true})^2\right)}$$

② Asymmetric Penalty Score

챌린지 특성에 따른 비대칭 점수 함수(제시됨)

$$A_{\{RUL\}} = \begin{cases} \exp(-\ln(0.5) \cdot Er_{i/20}) & \text{if } Er_i \leq 0 \\ \exp(+\ln(0.5) \cdot Er_{i/50}) & \text{if } Er_i > 0 \end{cases}$$

⚠ 핵심 주의사항

양수 오차(늦은 예측)는 더 가파르게 점수가 감점되므로, Early Stopping 기준도 Asymmetric Score 기반으로 설정 권장.

단계별 추진 로드맵 (Summary)

STEP 01

전처리 고도화

VMD + 스펙트럴 차감으로 고순도 특징 추출

RPM 기반 정규화 필수 선행

Bandpass 필터로 유효 주파수 대역 집중

STEP 02

데이터 보강

GAN + Time Warping으로 학습 데이터셋 확장

고장 근접 구간 집중 증강

Sobol Sampling으로 물리적 타당성 확보

STEP 03

모델 최적화

SVR → CNN-LSTM → PSR-Transformer 단계 검증

Asymmetric Huber Loss + LR Cosine Annealing

Domain Adaptation(ADTL/DANN) 적용

차후 일정

STEP 01

전처리 수행 및 데이터 확인

도메인, 구간별 전처리 시도 및 시각화

STEP 02

데이터 증강 보완

신호 속도 다변화, 이미지 보간

STEP 03

학습용 데이터 완성 및 전달 (~05.18)

감사합니다
